Assignment 04

K-means clustering

모듈 정의

그래프를 그리기 위해 Python3 matplotlib module 을 사용합니다

accuracy 측정을 위하여 Counter를 사용합니다.

처음 랜덤한 Centroid를 정하기 위하여 random 사용합니다.

In [176]:

```
import matplotlib.pyplot as plt
import numpy as np
import random
from collections import Counter
```

1. Apply K-means clustering to MNIST training dataset with different $K=5,\,10,\,15,\,20$ and present the following results for each K.

- K-means clustering을 K = 5,10,15,20으로 MNIST training dataset에 적용하고 각 K에 대해 결과를 제시합니다.
- mnist data를 사용하기 위해서 "mnist_train.csv"를 불러옵니다.

In [177]:

```
file_data = "mnist_train.csv"
handle_file = open(file_data, "r")
data = handle_file.readlines()
handle_file.close()
```

• 필요 함수 및 변수 선언

In [178]:

```
size_row = 28  # height of the image
size_col = 28  # width of the image
num_image = len(data)
count = 0  # count for the number of images

#  # normalize the values of the input data to be [0, 1]

#  def normalize(data):
    data_normalized = (data - min(data)) / (max(data) - min(data))
    return(data_normalized)

#  # make a matrix each column of which represents an images in a vector form
#  list_image = np.empty((size_row * size_col, num_image), dtype=float)
list_label = np.empty(num_image, dtype=int)
```

• data를 한 줄씩(feature data) 받아서 정규화하여 list_label, list_image로 구분하여 데이터 저장하고 cluster를 K 개수 만큼 생성 및 초기화

In [179]:

```
def init():
    for line in data:
        line_data = line.split(',')
        label = line_data[0]
        im_vector = np.asfarray(line_data[1:])
        im_vector = normalize(im_vector)
        global count
        list_label[count] = label
        list_image[:, count] = im_vector
        count += 1
```

• 모든 image 데이터(list_image) 중 k개 만큼의 centroid를 정합니다. (랜덤으로) 정하고 cluster_centroid안에 각각 넣습니다. cluster_centroid의 index는 cluster의 index와 같습니다.

In [180]:

```
# list_image안에 있는 데이터 중 k개의 centroid를 random 으로 select 한다.

def init_centroid_select_random(count,k):
    global cluster_centroid
    global list_image
    for i in range(1 , k+1):
        cluster_centroid[i] = list_image[:, random.randrange(1,count)]
```

• 각 cluster의 centroid를 정했다면 새로 들어오는 image에 대하여 centroid의 거리를 비교하여 가장 최소가 되는 거리의 cluster로 이동시킵니다. 반복되는 과정에서 cluster를 모두 비우고 채워 나갑니다. 즉, cluster를 비우고 연산 후 채워 넣고 centroid 계산하고 cluster를 비우고 연산 후 채우고 centroid를 계산하고.... 이 연산의 반복입니다.

In [181]:

```
# centroid  정했으면 centroids 과의 거리를 계산하여 그 해당 cluster로 이동시킨다.

def image2cluster(list_image,cluster,cluster_centroid,K):
    global count
    for i in range(1,K+1):
        cluster[i] = []
    minArr = []
    for i in range(0,count):
        for j in cluster:
            minArr.append(np.linalg.norm(list_image[:, i]-cluster_centroid[j]))
        cluster_index = minArr.index(min(minArr)) + 1
        cluster[cluster_index].append((list_label[i], list_image[:, i]))
        minArr = []
```

init_centroid_select_random 함수와 다르게 cluster 안에 있는 data의 centroid를 구하게 됩니다. (random이 아님)

$$M_k = \frac{\sum_{i \in C_k} x_i}{N}$$

 M_k 는 centroid 입니다. N은 해당 클러스터 안의 모든 image의 수입니다. C_k 는 해당 클러스터입니다 centroid는 해당 클러스터안에 모든 image vector를 더하여 해당 클러스터의 모든 image의 수로 나눈 값입니다. 위의 연산을 구현하여 각 클러스터 별로 centroid를 구하여 cluster_centroid에 넣습니다.

In [182]:

```
def centroid_select(list_image,cluster,cluster_centroid):
    for i in cluster:
        labels,images = zip(*cluster[i])
        centroid = np.sum(np.array(images), axis = 0) / len(images)
        cluster_centroid[i] = centroid
```

• energy function의 값을 구하는 함수입니다.

$$\frac{1}{K} \sum_{k=1}^{K} \|x_i - c_{k_i}\|^2$$

• where k_i denotes the category of x_i , and c_{k_i} denotes the centroid of category x_i .

위 연산을 구현한 것으로 해당 클러스터의 image vectors와 centroid의 norm을 구하고 클러스터별 value를 모두 더하여 K만큼 나눕니다.

In [183]:

```
def get_energyfunction_val(cluster,cluster_centroid,K):
    val = 0
    for i in cluster:
        labels,images = zip(*cluster[i])
        val = val + np.linalg.norm(images - cluster_centroid[i])
    return val / K
```

• accuracy를 구하는 함수입니다.

$$\frac{\sum_{k=1}^{K} m_k}{N}$$

• where N denotes the total number of data, and m_k denotes the number of data with majority for category k.

위 연산을 구현한 것으로 Counter의 most_common() 함수로 가장 많이 포함되어있는 category의 수를 모든 image data 로 나누어 구합니다.

1에 가까울수록 정확하다고 볼 수 있습니다.

In [184]:

```
def get_accuracy_val(cluster):
    most = 0
    labels_count = 0


for i in cluster:
        labels,images = zip(*cluster[i])
        most = most + Counter(labels).most_common()[0][1]
        labels_count = labels_count + len(labels)
    return most/labels_count
```

2. Visualize K centroid images for each category.


- K 중심 이미지를 시각화합니다.
- iterator는 10으로 설정합니다.


```
In [185]:
```


```
K list = [5, 10, 15, 20]
iterator = 10
init()
for K in K list:
    cluster = {}
    cluster_centroid = {}
    for i in range(1,K+1):
        cluster[i] = []
    init centroid select random(count,K)
    image2cluster(list image,cluster,cluster centroid,K)
    energy = []
    accuracy = []
    for x in range(0,iterator):
        centroid select(list image,cluster,cluster centroid)
        image2cluster(list image,cluster,cluster centroid,K)
        energy.append(get_energyfunction_val(cluster,cluster_centroid,K))
        accuracy.append(get accuracy val(cluster))
    for i in cluster:
        labels,images = zip(*cluster[i])
        most = Counter(labels).most common()[0][0]
                   = cluster_centroid[i].reshape((size_row, size_col))
        im matrix
        plt.subplot(1, 5, 1)
        plt.title("K: " + str(K)+" / "+str(i)+"cluster centroid/major: "+ str(
most))
        plt.imshow(im matrix, cmap='Greys', interpolation='None')
        frame
                = plt.gca()
        frame.axes.get xaxis().set visible(False)
        frame.axes.get_yaxis().set_visible(False)
        plt.show()
```
























K: 10 / 6cluster centroid/major: 0



K: 10 / 7cluster centroid/major: 7



K: 10 / 8cluster centroid/major: 4



K: 10 / 9cluster centroid/major: 1



K: 10 / 10cluster centroid/major: 2



K: 15 / 1cluster centroid/major: 4




K: 15 / 2cluster centroid/major: 0




K: 15 / 3cluster centroid/major: 1

























K: 20 / 1cluster centroid/major: 8



K: 20 / 2cluster centroid/major: 6



K: 20 / 3cluster centroid/major: 3



K: 20 / 4cluster centroid/major: 6





K: 20 / 5cluster centroid/major: 7



K: 20 / 6cluster centroid/major: 5









K: 20 / 10cluster centroid/major: 9



K: 20 / 11cluster centroid/major: 4



K: 20 / 12cluster centroid/major: 0



K: 20 / 13cluster centroid/major: 1



K: 20 / 14cluster centroid/major: 0



K: 20 / 15cluster centroid/major: 3



K: 20 / 16cluster centroid/major: 6



K: 20 / 17cluster centroid/major: 1



K: 20 / 18cluster centroid/major: 7



K: 20 / 19cluster centroid/major: 0



K: 20 / 20 cluster centroid/major: 7




3. Plot the training energy per optimization iteration.

- 반복하며 training energy 를 plot합니다.
- (training energy) is computed on the training dataset.

In [187]:

```
plt.xlabel("iterator")
plt.ylabel("energy")
plt.plot(range(0,iterator), energy)
plt.show()
```




4. Plot the training accuracy per optimization iteration.

- 반복하며 training accuracy를 plot합니다.
- (training accuracy) is computed on the training dataset.

In [188]:

```
plt.xlabel("iterator")
plt.ylabel("accuracy")
plt.plot(range(0,iterator), accuracy)
plt.show()
```




5. Plot the testing accuracy per optimization iteration.

- 반복하며 testing accuracy를 plot합니다.
- (testing accuracy) is computed on the testing dataset.

In [189]:

```
file data
           = "mnist test.csv"
handle_file = open(file_data, "r")
            = handle file.readlines()
data
handle file.close()
num image
           = len(data)
count
           = 0
list_image = np.empty((size_row * size_col, num_image), dtype=float)
list label = np.empty(num image, dtype=int)
for line in data:
    line data = line.split(',')
   label
               = line data[0]
   im vector = np.asfarray(line data[1:])
    im vector = normalize(im_vector)
    list label[count]
                            = label
   list_image[:, count] = im_vector
   count += 1
accuracy test = []
image2cluster(list_image,cluster,cluster_centroid,K)
for x in range(0,iterator):
   centroid_select(list_image,cluster,cluster_centroid)
    image2cluster(list_image,cluster,cluster_centroid,K)
   accuracy_test.append(get_accuracy_val(cluster))
plt.clf()
plt.xlabel("iterator")
plt.ylabel("accuracy")
plt.plot(range(0,iterator), accuracy_test)
plt.show()
```



In []: